



北京交通大学

图像处理与机器学习

Digital Image Processing and Machine Learning

主讲人：黄琳琳

电子信息工程学院




第八章 非监督学习

- ◆ 引言
- ◆ 聚类算法
- ◆ 主成份分析



主成份分析

➤ 举例：手写字符识别



- 维度过高引起过拟合
- 特征之间具有相关性

降维

主成份分析

(Principal Component Analysis, **PCA**)



主成份分析

◆ PCA又称为K-L变换 (Karhunen–Loève transform)

- 1901 年Pearson 在研究回归分析时附带提出的
- 1933 年由Hotelling 奠定数学基础。
- 1947年美国统计学家斯通(stone)应用到经济分析



主成份分析

- ◆ 1947年美国的统计学家斯通, 对经济研究时
 - 利用美国1929—1938年各年的数据
 - 得到了17个反映国民收入与支出的变量

- ✓ 雇主补贴
- ✓ 消费资料和生产资料
- ✓ 纯公共支出
- ✓ 净增库存
- ✓ 股息
- ✓ 利息
- ✓ 外贸平衡等等
-

主成分分析
(PCA)

→ 三个新变量

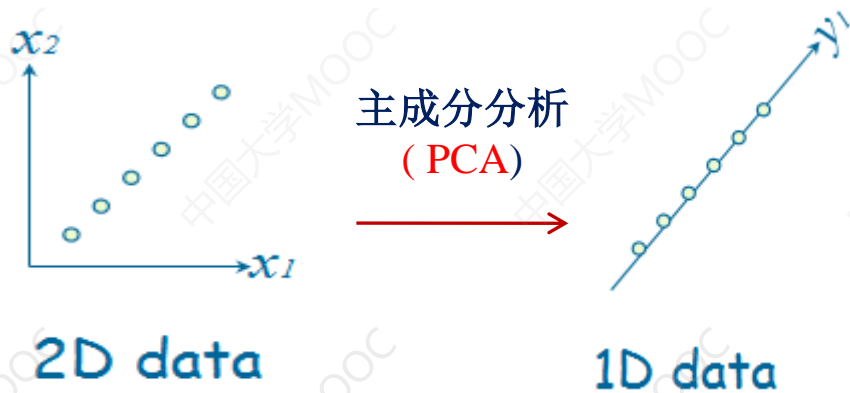
97.4% 分析精度



主成份分析

◆ PCA 试图在力保数据**信息丢失最少**的原则下

- 对**多变量**数据进行最佳**综合简化**
- 对高维变量空间进行 **降 维** 处理





主成份分析

◆ PCA可以通过求解特征矢量来得到主成份
实对称矩阵 Σ

-- 特征矢量及特征值 $\Sigma\phi_i = \lambda_i\phi_i$

-- 特征矢量构成正交特征空间

$$\Phi = [\phi_1, \phi_2, \dots, \phi_d] \quad \Lambda = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_d]$$

$$\begin{aligned} \Phi^T \Phi &= I \\ \Phi^T &= \Phi^{-1} \end{aligned} \quad \longleftrightarrow \quad \phi_i^t \phi_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$



主成份分析

◆ 实对称矩阵 Σ

$$\Sigma \phi_i = \lambda_i \phi_i \quad \Phi = [\phi_1, \phi_2, \dots, \phi_d]$$

$$\Lambda = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_d]$$

$$\Sigma \Phi = \Phi \Lambda \quad \Sigma = \Phi \Lambda \Phi^T$$

$$\Phi^T \Sigma \Phi = \Lambda = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_d \end{bmatrix}$$

矩阵对角化



主成份分析

◆ 应用：Principal component analysis (PCA)

- 利用 n 个样本矢量求取**协方差矩阵**
- 求取协方差矩阵的特征矢量及特征值
- 将特征矢量按照特征值由大到小排序
- 选择特征值最大的 m ($m < d$) 个特征向量构成低维子空间
- 将随机矢量投影到**低维子空间**
- 使子空间投影的**重建误差最小**




主成份分析

$$\Sigma = \Phi \Lambda \Phi^T \quad \Lambda = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_d]$$

特征矢量按照特征值由大到小排序

$$\Phi = [\phi_1, \phi_2, \dots, \phi_d] \quad \lambda_1 > \lambda_2, \dots, > \lambda_d$$




特征矢量构成
正交特征空间



主成份分析

◆ 应用：Principal component analysis (PCA)

- 将随机矢量投影到**低维子空间**
- 投影即为该矢量特征表达（低维）





主成份分析

线性空间中正交变换($\Phi^T \Phi = I$) 不影响欧氏距离

$$\sum_{j=1}^d [(\mathbf{x} - \mu)^T \phi_j]^2 = \|\mathbf{x} - \mu\|^2$$


子空间投影 $\mu + \sum_{j=1}^m [(\mathbf{x} - \mu)^T \phi_j] \phi_j$

投影重建误差

$$r_E = \|\mathbf{x} - \mu\|^2 - \sum_{j=1}^m [(\mathbf{x} - \mu)^T \phi_j]^2 = \sum_{j=m+1}^d [(\mathbf{x} - \mu)^T \phi_j]^2$$

期望

$$\begin{aligned} \mathcal{E}(r_E) &= \mathcal{E} \left\{ \sum_{j=m+1}^d [(\mathbf{x} - \mu)^T \phi_j]^2 \right\} = \mathcal{E} \left\{ \sum_{j=m+1}^d \phi_j^T (\mathbf{x} - \mu)(\mathbf{x} - \mu)^T \phi_j \right\} \\ &= \sum_{j=m+1}^d \phi_j^T \mathcal{E}[(\mathbf{x} - \mu)(\mathbf{x} - \mu)^T] \phi_j = \sum_{j=m+1}^d \phi_j^T \Sigma \phi_j = \sum_{j=m+1}^d \lambda_j \end{aligned}$$





谢 谢

本课程所引用的一些素材为主讲老师多年的教学积累，来源于多种媒体及同事和同行的交流，难以一一注明出处，特此说明并表示感谢！